Phân tích và dự đoán chất lượng rượu vang đỏ bằng các thuật toán Machine Learning

- 3124411174 Tất Võ Tiến Nam
- 3124411166 Phạm Anh Minh
- 3124411116 Lê Long Hưng

DCT124C1

MỤC LỤC

1. Giới thiệu
2. Phân tích bài toán
3. Phương pháp và quá trình thử nghiệm
4. Kết quả đánh giá
5. Hướng cải tiến mô hình
6. Tài liệu tham khảo

1 GIỚI THIỆU

- **Bối cảnh:** Thay thế phương pháp thử nếm truyền thống tốn kém và chủ quan bằng hệ thống phân loại tự động dựa trên 11 đặc trưng hóa lý.
- **Quy trình triển khai:** Từ tiền xử lý, đánh giá 10 thuật toán Baseline, đến tối ưu hóa siêu tham số và áp dụng Ensemble Learning (Stacking).

- **Mục tiêu:** Xây dựng mô hình học máy phân loại đa lớp để dự đoán nhãn chất lượng rượu
- **Kết quả nổi bật:** Họ thuật toán Ensemble (Random Forest, Stacking) cho thấy sự vượt trội trên dữ liệu nhỏ, khắc phục overfitting và xử lý tốt ranh giới phi tuyến tính.

2 PHÂN TÍCH BÀI TOÁN

Bối cảnh & Định nghĩa bài toán

- **Vấn đề:** Đánh giá chất lượng rượu quy mô lớn cần một hệ thống tự động ánh xạ từ các chỉ số hóa học phòng thí nghiệm sang điểm số chuyên gia.
- **Loại bài toán:** Hồi quy (Regression) - Dự đoán điểm chất lượng rượu vang.
- **Mục tiêu cốt lõi:** Tìm ra hàm ánh xạ tối ưu nhất.
  - **Đầu vào (Input):** 11 đặc trưng hóa lý học của rượu vang (độ axit, nồng độ cồn, lượng đường dư,...).
  - **Đầu ra (Output):** Biến phân loại quality (từ 3 đến 8).

2 PHÂN TÍCH BÀI TOÁN

Thách thức kĩ thuật:

- Mất cân bằng dữ liệu nghiêm trọng.
- Tương tác hóa học phức tạp, ranh giới quyết định phi tuyến.
- Biên độ biến thiên giữa các đặc trưng (thang đo) rất khác biệt.

- **MSE (Mean Squared Error):** Sai số bình phương trung bình. Dùng để phạt nặng các dự đoán lệch chuẩn quá xa.
- **MAE (Mean Absolute Error):** Sai số tuyệt đối trung bình. Đánh giá xem trung bình mô hình dự đoán lệch bao nhiêu điểm so với thực tế.

2 PHÂN TÍCH BÀI TOÁN

Mô tả dữ liệu

- Nguồn gốc: "Wine Quality Dataset" (Red Wine) thu thập từ Bồ Đào Nha.
- Kích thước: 1599 mẫu thử, mỗi mẫu gồm 11 biến độc lập (hóa lý) và 1 biến mục tiêu

Tính chất Acid	Thành phần và Vị Giác	Chất bảo quản	Biến mục tiêu
Fixed acidity, volatile acidity, citric acid, pH.	Residual sugar, chlorides, density, alcohol.	Free sulfur dioxide, total sulfur dioxide, sulphates.	Quality (0-10).

2 PHÂN TÍCH BÀI TOÁN

Phân tích dữ liệu (EDA)

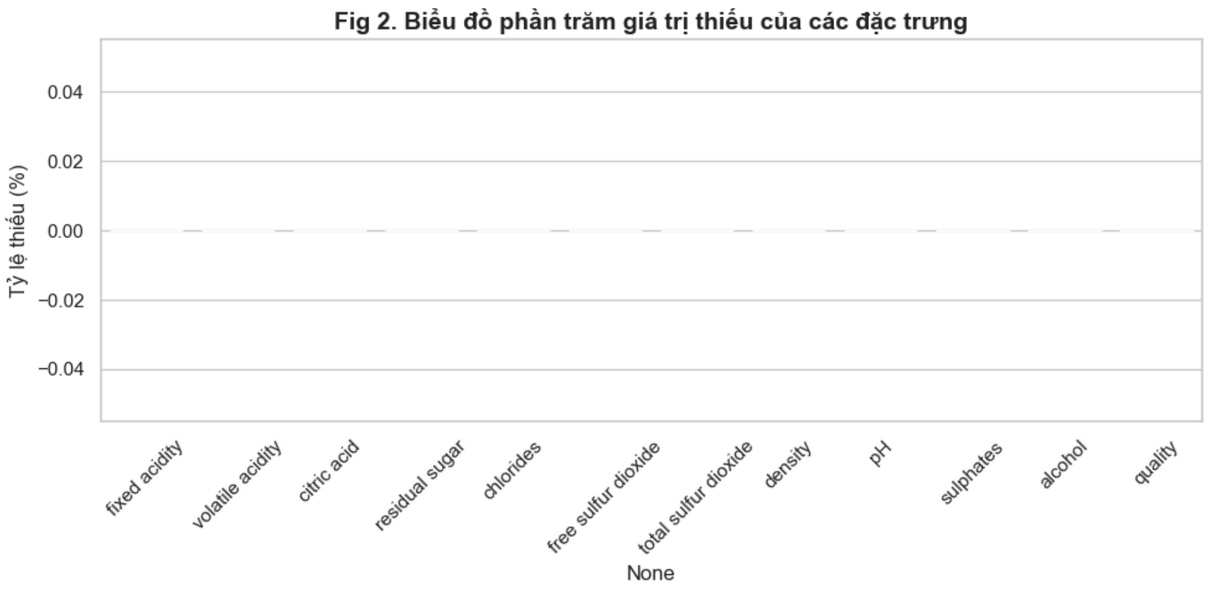

tỷ lệ thiếu 0% nên không cần nội suy.

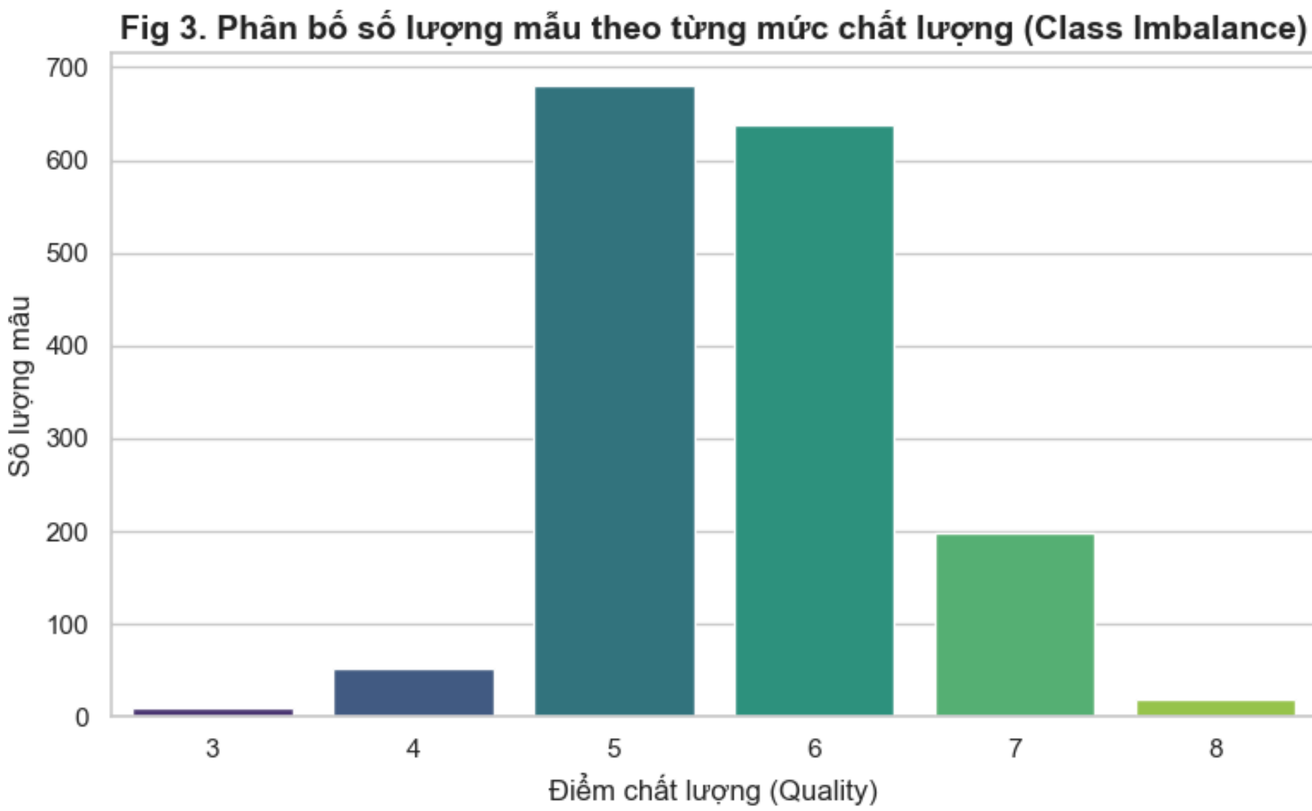

Tính toàn vẹn & Phân phối biến dữ liệu

Phân bố đặc trưng & Hiện tượng ngoại lai

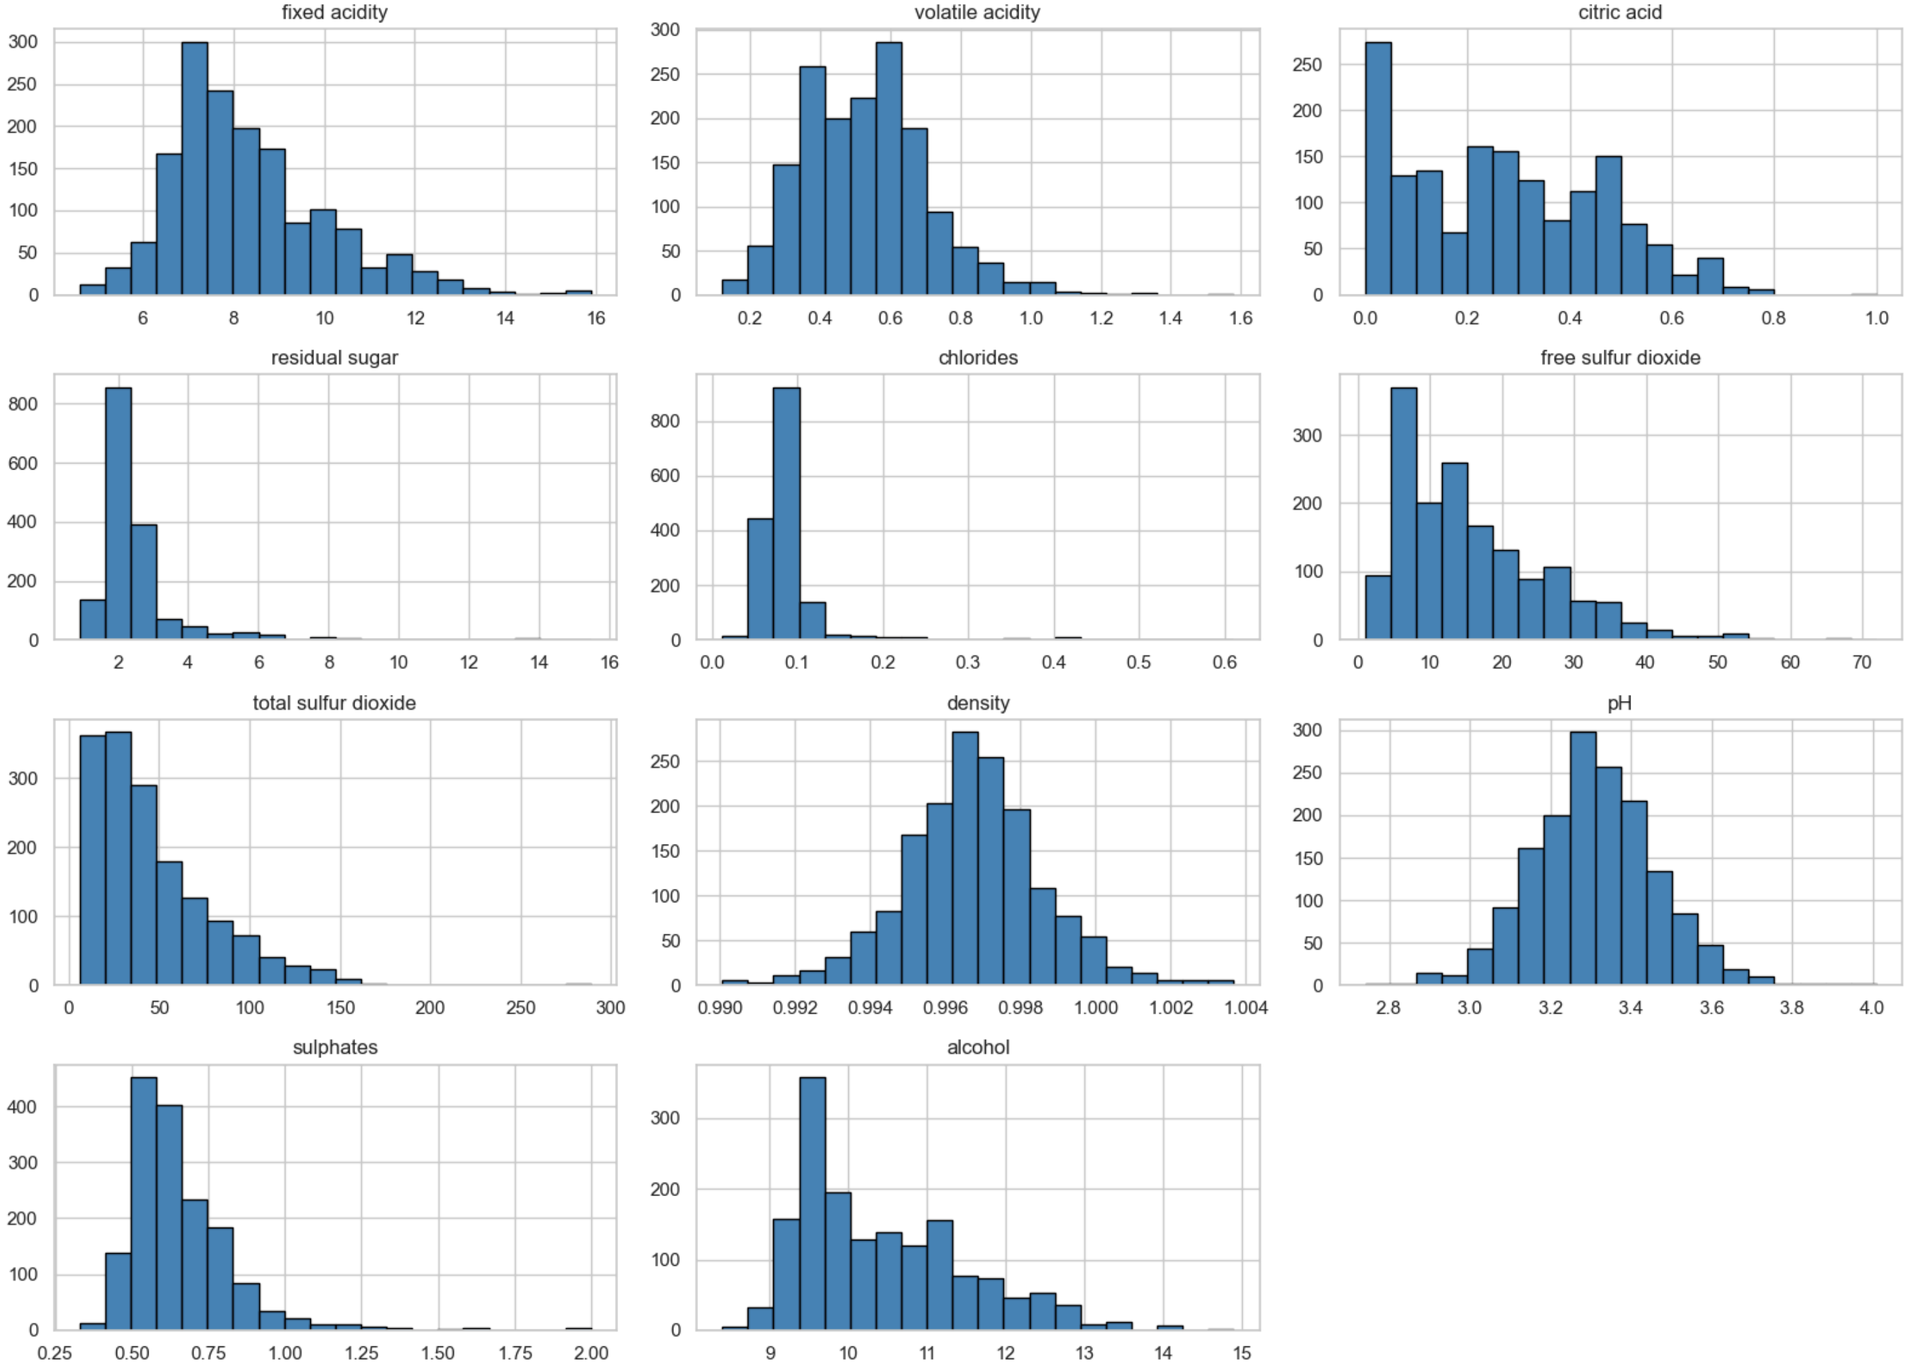

Biểu đồ phân bố giá trị của các đặc trưng hoá lý

Phân bố đặc trưng & Hiện tượng ngoại lai

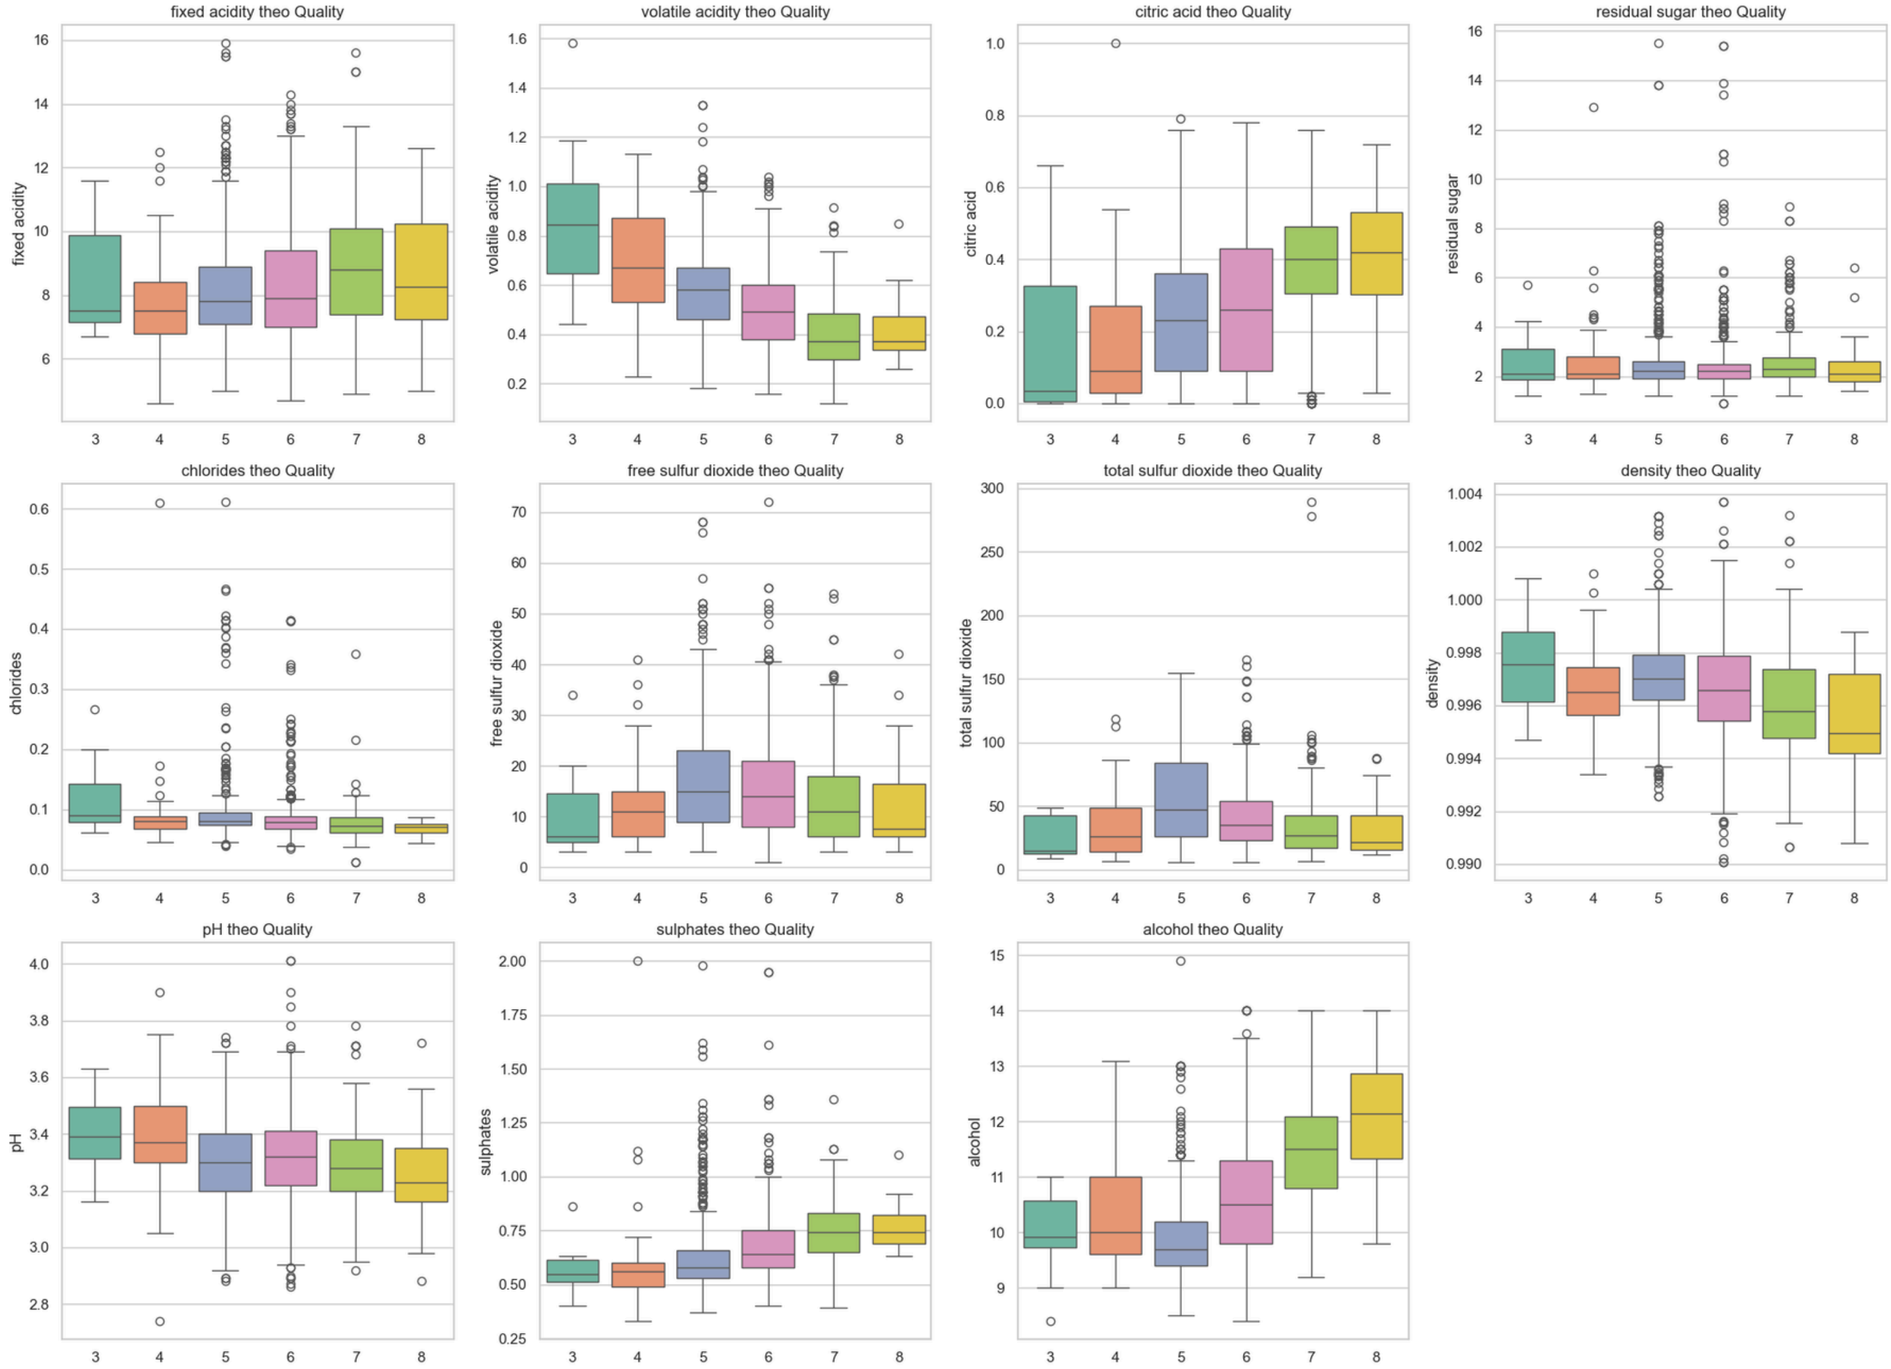

Boxplot mô tả sự phân tán và chồng lấn dữ liệu giữa các lớp

2 PHÂN TÍCH BÀI TOÁN

Sự tương quan

- Alcohol có tương quan thuận mạnh nhất với chất lượng (r = 0.48).
- Volatile acidity có tương quan nghịch mạnh nhất (r = -0.39).

Sự chồng lấn dữ liệu và Ranh giới quyết định phi

- Giao thoa dữ liệu giữa các lớp (đặc biệt 5 và 6) là rất lớn. Các cụm UMAP cuộn xoắn và đan xen phức tạp.
- Kết luận: Cần sử dụng Ensemble Learning hoặc Mạng nơ-ron sâu để phân loại hiệu quả.

2 PHÂN TÍCH BÀI TOÁN

Fig 8. Trực quan hóa dữ liệu bằng phương pháp giảm chiều UMAP

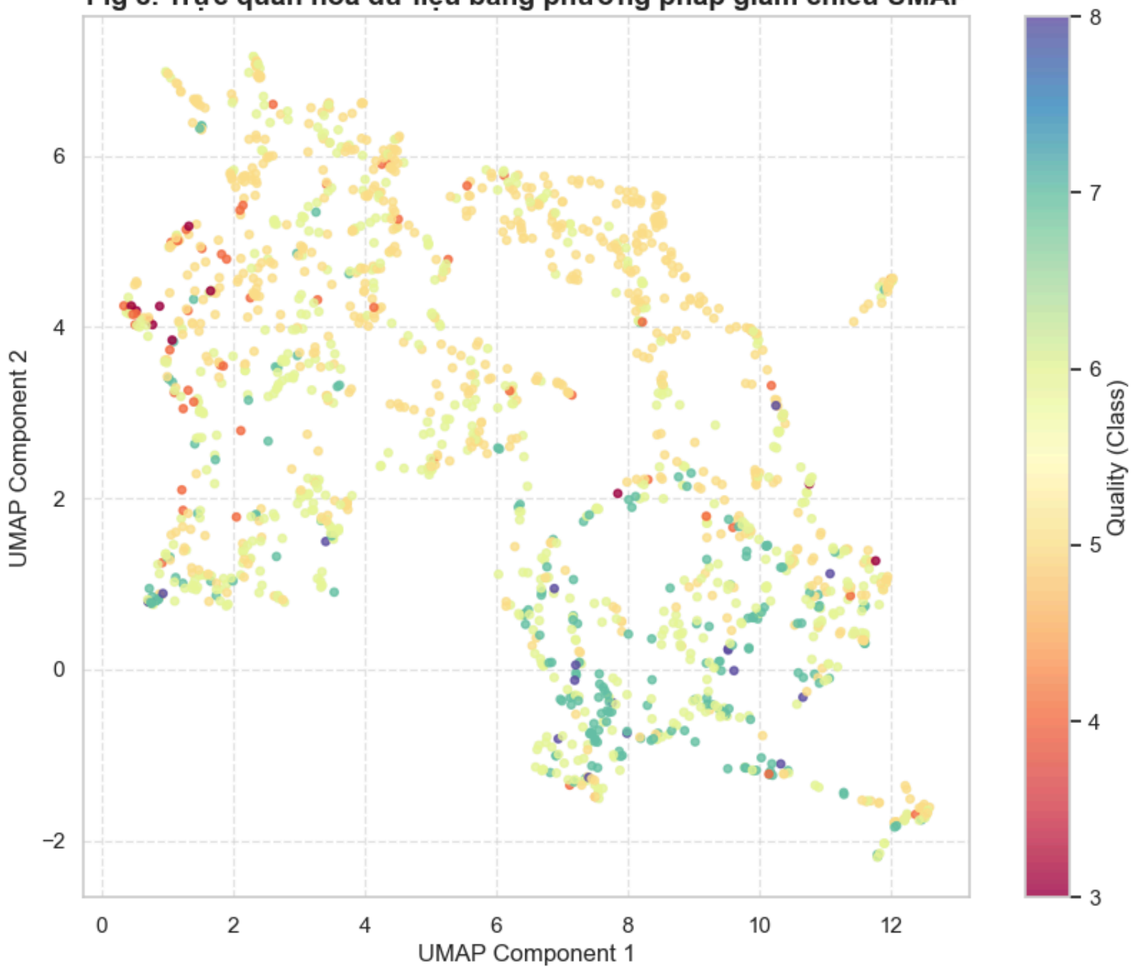

Fig 7. Pairplot biểu diễn sự giao thoa dữ liệu ở các đặc trưng quan trọng

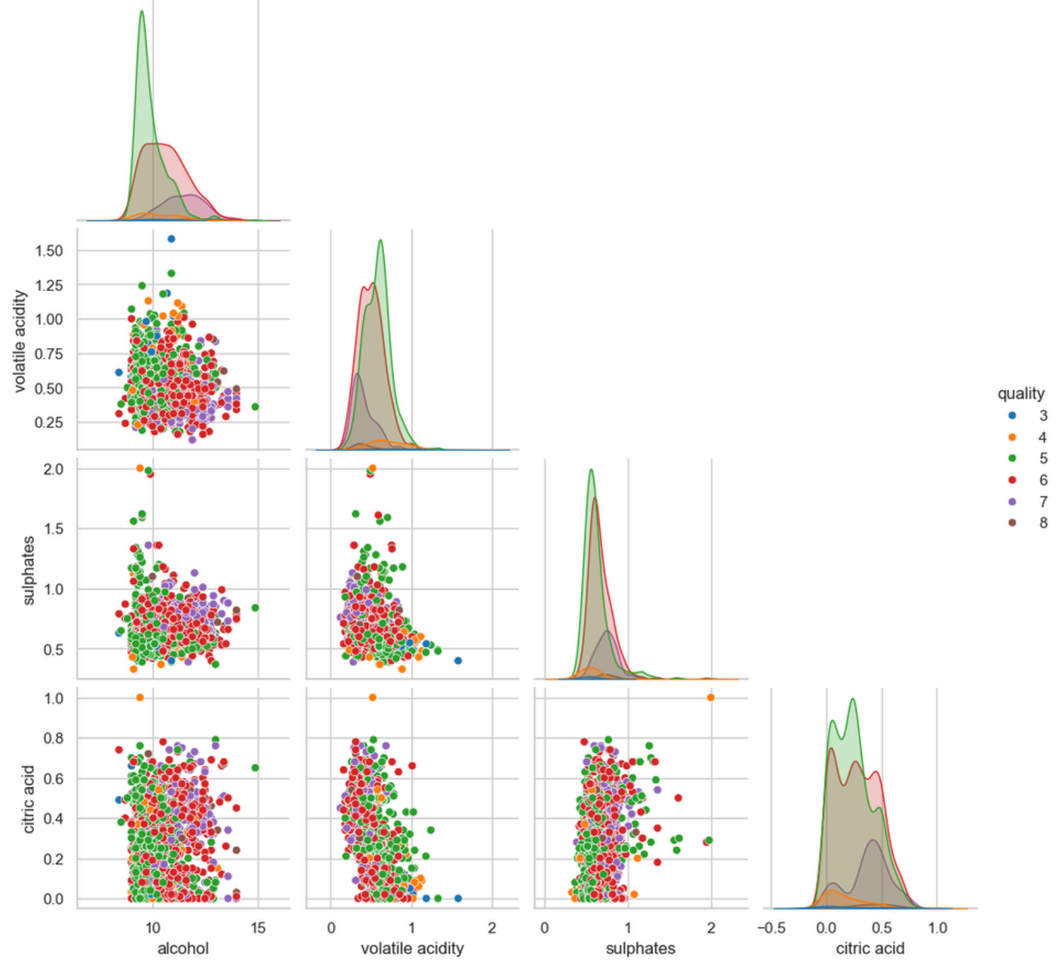

3 PHƯƠNG PHÁP QUÁ TRÌNH THỰC NGHIỆM

5 phương pháp tối ưu hóa chuyên sâu:

- **Chuẩn hóa dữ liệu:** Áp dụng StandardScaler để đưa đặc trưng về cùng thang đo.
- **Lựa chọn đặc trưng (Feature Selection):** Lọc các biến có ý nghĩa nhất.
- **GridSearchCV:** Dò tìm tự động bộ siêu tham số tối ưu nhất cho từng thuật toán.
- **Cross-Validation:** Kiểm định chéo để mô hình học khách quan, không bị Overfitting.
- **Ensemble Learning (Stacking):** Kết hợp các mô hình mạnh để đưa ra dự đoán cuối cùng.

3 PHƯƠNG PHÁP QUÁ TRÌNH THỰC NGHIỆM

Thiết lập thử nghiệm Baseline

- **Chiến lược:** Đánh giá đồng thời 10 thuật toán cơ sở để tìm ra "ứng cử viên" sáng giá nhất
- **Danh sách thuật toán:** MLP Regressor, k-Neighbors Regressor, Random Forest, SVR, SGD Regressor, Decision Tree, Gradient Boosting,Linear Regression, Linear SVR, và Ridge Regression.
- **Kiểm định:** Sử dụng K-Fold Cross Validation (K=5) để đảm bảo tính khách quan, tránh hiện tượng "ăn may" trên một tập dữ liệu cụ thể.

3 PHƯƠNG PHÁP QUÁ TRÌNH THỰC NGHIỆM

Tối ưu hóa

- **GridSearchCV:** Tự động dò tìm bộ siêu tham số (hyperparameters) tối ưu (như n_estimators, max_depth).

Kỹ thuật Stacking (Ensemble):

- Sử dụng các mô hình cây (Random Forest, Gradient Boosting) làm base-models và một mô hình Meta-model để đưa ra quyết định cuối cùng.
  - Mục tiêu làm giảm thiểu sai số MSE và tăng độ ổn định.

4 KẾT QUẢ VÀ ĐÁNH GIÁ

Hiệu năng mô hình

Thuật toán	MSE	RMSE	MAE	R2-Score	Time (s)
Linear Regression	0.41	0.64	0.51	0.35	3.02
k-Neighbors Regressor	0.46	0.68	0.51	0.28	0.06
SVR (Support Vector)	0.38	0.62	0.47	0.41	0.28
Decision Tree	0.62	**0.79**	**0.45**	**0.02**	**0.06**
Random Forest	0.35	0.59	0.44	0.45	3.02

Hiệu năng mô hình

Thuật toán	MSE	MAE	RMSE	R2-Score	Time(s)
Gradient Boosting	**0.39**	**0.62**	**0.49**	**0.39**	**1.12**
MLP Regressor	0.40	0.63	0.49	0.38	15.78
Linear SVR	0.42	0.65	0.51	0.33	0.06
Ridge Regression	0.41	**0.64**	**0.51**	**0.35**	**0.02**
SGD Regressor	0.41	0.64	0.51	0.35	0.02

4 KẾT QUẢ VÀ ĐÁNH GIÁ

2 mô hình chạy tốt nhất là Random Forest và SVR vì có RMSE thấp nhất. Ở đây sẽ có SVR và Gradient boosting cùng có RMSE là 0.62 nên sẽ chuyển qua xét MSE thì SVR có MSE thấp hơn là 0.38

	Algorithm	MSE	RMSE	MAE	RSE	Time (s)
4	Random Forest	0.35	0.59	0.44	0.45	3.02
7	SVR	0.38	0.62	0.47	0.41	0.28

5 TỒN TẠI HƯỚNG CẢI TIẾN

Trực quan hóa kết quả dự đoán

- **Độ hội tụ:** Đồ thị Loss giảm dần và ổn định qua các Epoch, cho thấy mô hình không bị Overfitting hay Underfitting.

- **Sai số dự đoán:** Biểu đồ so sánh giá trị Thực tế (Actual) vs Dự đoán (Predicted) bám sát đường chéo 45 độ.

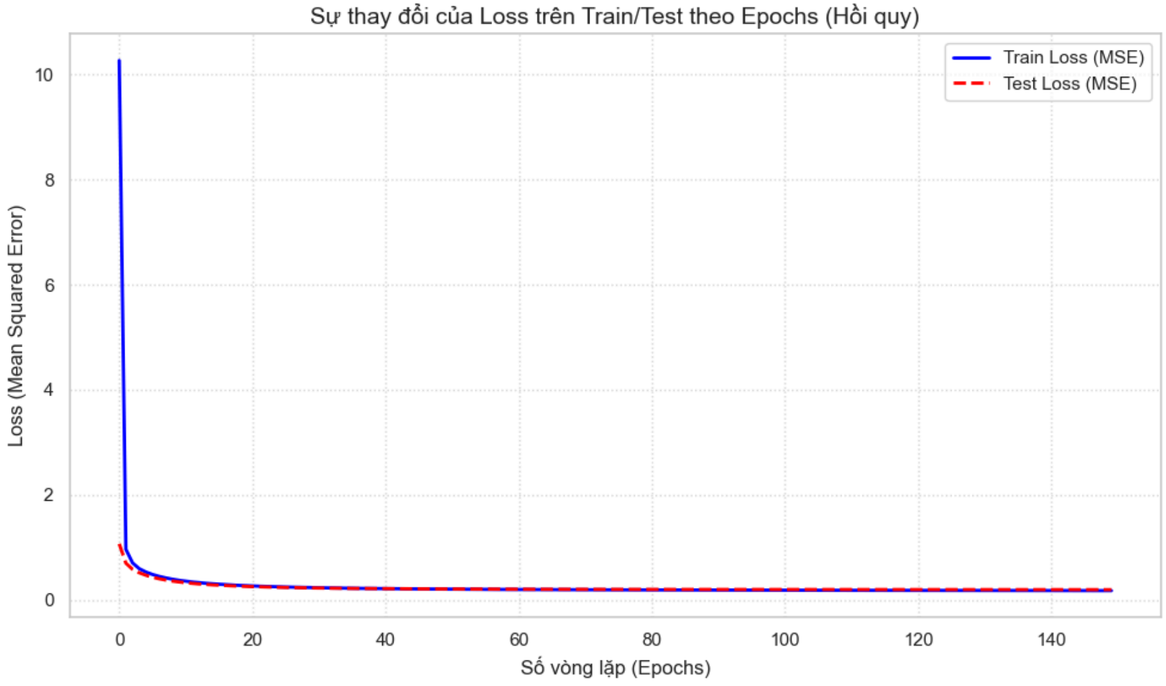

5 TỒN TẠI HƯỚNG CẢI TIẾN

Hạn chế hiện tại: Dữ liệu còn nhỏ (1599 mẫu), thiếu các thông tin ngoại cảnh như giống nho hay thời gian ủ men.

Hướng phát triển:

- Khai thác thêm các thông tin hữu cơ trong quá trình ủ rượu như: giống nho, độ tuổi của thùng gỗ sồi, thời gian lên men thay vì chỉ đo lường hóa học. Mục tiêu kéo giảm sai số tuyệt đối (MAE) tiến sát về mức 0.
- Deep Learning: Thử nghiệm các mạng nơ-ron sâu (MLP, Transformer cho dữ liệu bảng) khi tập dữ liệu lớn hơn.
- Ứng dụng thực tế: Triển khai mô hình thành Web App hoặc API để hỗ trợ các nhà sản xuất rượu đánh giá nhanh tại phòng thí nghiệm.

6 TÀI LIỆU THAM KHẢO

1. P. Cortez et al., "Modeling wine preferences by data mining...", Decision Support Systems, 2009.
2. UCI Machine Learning Repository, "Wine Quality Data Set," 2009. [Online]. Available: [2] UCI Machine Learning Repository, "Wine Quality Data Set", 2009.[Accessed: April 5, 2026].
3. Scikit-learn documentation: Machine Learning in Python.
4. L. Breiman, "Random Forests", Machine Learning journal, 2001.

Thank you for your guidance<3